# INDEXING

# Indexing

- Pengindeksan secara manual (oleh manusia)
  - Menentukan kata kunci dari suatu dokumen berdasarkan perbendaharaan kata yang ada (controlled vocabulary)
  - Oleh ahli di bidangnya
  - Lama dan mahal
- Pengindeksan secara otomatis
  - Program komputer untuk menentukan kata atau frase tertentu dari teks pada dokumen
  - Prosesnya cepat

# Indexing

| | Manual | Automatic |
|---|---|---|
| Controlled vocabulary | Catalogization | Categorization |
| Free text | Indexing | Search engine |

# Tahapan Indeksisasi Otomatis

- Perhatikan struktur dokumen (id, tanggal, author, title, text, dsb)
- Tokenisasi
- Buang stopwords
- Proses pemotongan imbuhan (stemming)
- Pembobotan kata
- Pembuatan indeks

# Struktur Dokumen

- Tergantung jenis dokumen
- Format umum : SGML (Standard Generalized Markup Language)
- Perlu pemisahan antar elemen dokumen?
- Bagian mana saja dari dokumen yang akan diindeks?

# Tokenisasi

- Kata atau konsep?
  - Kata sederhana (tunggal)
  - Frase
  - Konsep→Thesaurus
- Teknik: segmentasi, memilah
- Tokenisasi :: Frase
  - Contoh frase : tusuk jarum
  - Banyak menggunakan metode statistika
  - Berdasarkan frekuensi kemunculan
  - POS-tagger

# Stopword

- Kata buangan, daftar kata umum yang mempunyai fungsi tapi tidak mempunyai arti
- Contoh : dan, atau, yang
- Dari pengalaman, frekuensinya sangat banyak
- Dibuang, untuk efisiensi
- Timbul masalah, misalkan :
    - Yang Mulia
    - Yang Maha Kuasa
    - Ekspresi DAN bernilai benar jika kedua operand bernilai benar

# Stemming

- Proses pembuangan prefiks dan sufiks (secara morfologi) dari suatu kata berimbuhan menjadi kata dasar.
- Contoh: menyelesaikan → selesai (stem)
- Stemming dilakukan atas dasar asumsi bahwa kata-kata yang memiliki stem yang sama memiliki makna yang serupa pula.

# Tujuan Stemming

- Efisiensi, mengurangi jumlah kata-kata unik dalam indeks sehingga mengurangi kebutuhan ruang penyimpanan untuk indeks dan mempercepat proses pencarian.
- Efektivitas, meningkatkan dokumen yang ditemu-kembalikan (recall) dengan mengurangi varian kata menjadi bentuk kata dasarnya (stem).

# Masalah Stemming

- Umum dilakukan dalam IR walaupun hasilnya banyak bermasalah.
- Contoh:
  - Kadaluarsa → ngadaluarsa
  - Mencapai → capa
- Stemming akan menghilangkan variasi morfologi.
  - kabar : berkabar, mengabarkan, terkabar, perkabaran, pengabaran

# Teknik Stemming

Teknik stemming dapat dikategorikan menjadi tiga jenis:

- Berdasarkan aturan sesuai bahasa tertentu,
- Berdasarkan kemunculan bersama,
- Berdasarkan kamus.

# Porter Stemming

- Stemmer untuk bahasa Inggris yang terdiri dari beberapa aturan, dikembangkan oleh Martin Porter.
- Dasar algoritme Porter berdasarkan pemotongan awalan(prefix) dan akhiran(suffix):
    - Penghitungan ukuran kata
    - Aturan pemotongan.

# Ukuran Kata

- Setiap kata/bagian kata dapat memiliki salah satu dari empat bentuk:

  KVKV ... K

  KVKV ... V

  VKVK ... K

  VKVK ... V

- Bentuk umum:

  [K]VKVK ... [V] atau

  [K] (VK)m [V]

  dimana m melambangkan ukuran kata

# Ukuran Kata

Contoh:

”makan” dan ”bentuk” : m=2

”presentasi” dan ”dimanakah” : m=4

- Fungsi penghitung ukuran kata digunakan untuk mencegah stemming menghasilkan stem yang terlalu pendek (overstemming).
- Diasumsikan minimal stem berukuran dua, kecuali jika kata berukuran kurang dari dua.

# Ukuran Kata

- Aturan: P1 (kondisi) S1 → P2 S2
- Artinya jika kata memiliki prefiks P1 dan sufiks S1, dan bagian kata setelah P1 dan sebelum S1 memenuhi kondisi atau aturan yang diberikan, maka P1 dan S1 akan diganti menjadi P2 dan S2.
- Kondisi dapat menggunakan operator AND, OR, atau NOT untuk menyatakan aturan yang kompleks.

# Contoh

- (m>1) wan →
- berarti S1 adalah wan, dan S2 adalah null (kata kosong).
- Contoh: kata ”dermawan” dipotong menjadi ”derma” karena ”derma” berukuran 2 (m>1).

# Program Stemmer

- Berbagai implementasi Porter Stemmer untuk bahasa Inggris:
  - http://www.tartarus.org/~martin/PorterStemmer/
- Untuk bahasa Indonesia, lihat :
  - UI : Neil Siregar (1995)
  - UI : Adriani & Nazief (1996)
  - IPB : Ahmad Ridha (2002), Julio Adisantoso (2009)
- Bantuan kamus.

# Teknik stemming

- Periksa semua kemungkinan bentuk kata: prefiks1+prefiks2+KATADASAR+sufiks3+sufiks2+sufiks1
- Lakukan pemotongan berurutan : prefiks1, prefiks2, sufiks1, sufiks2, sufiks3 (kalau ada), dan KATADASAR.
- Setiap tahap pemotongan diikuti dengan pemeriksaan di kamus kata dasar). Jika ada maka proses dinyatakan selesai.
- Contoh : kata mempermainkannya :
- Jika sampai pada pemotongan sufiks3 masih belum ada di kamus, maka dilakukan proses kombinasi.

# Kombinasi kata

- Kata Dasar
- Kata Dasar + Akhiran 3
- Kata Dasar + Akhiran 3 + Akhiran 2
- Kata Dasar + Akhiran 3 + Akhiran 2 + Akhiran 1
- Awalan 1 + Awalan 2 +Kata Dasar
- Awalan 1 + Awalan 2 +Kata Dasar + Akhiran 3
- Awalan 1 + Awalan 2 +Kata Dasar + Akhiran 3 + Akhiran 2
- Awalan 1 + Awalan 2 +Kata Dasar + Akhiran 3 + Akhiran 1
- Awalan 2 + Kata Dasar
- Awalan 2 + Kata Dasar + Akhiran 3
- Awalan 2 + Kata Dasar + Akhiran 3 + Akhiran 2
- Awalan 2 + Kata Dasar + Akhiran 3 + Akhiran 2 + Akhiran 1

# Awalan me-

- tetap, jika huruf pertama kata dasar adalah l, m, n, q, r, atau w. Contoh: me- + luluh → meluluh, me- + makan → memakan.
- me- → mem-, jika huruf pertama kata dasar adalah b, f, p*, atau v. Contoh: me- + baca → membaca, me- + pukul → memukul*, me- + vonis → memvonis, me- + fasilitas + i → memfasilitasi.
- me- → men-, jika huruf pertama kata dasar adalah c, d, j, atau t*. Contoh: me- + datang → mendatang, me- + tiup → meniup*.
- me- → meng-, jika huruf pertama kata dasar adalah huruf vokal, k*, g, h. Contoh: me- + kikis → mengikis*, me- + gotong → menggotong, me- + hias → menghias.
- me- → menge-, jika kata dasar hanya satu suku kata. Contoh: me- + bom → mengebom, me- + tik → mengetik, me- + klik →mengeklik.
- me- → meny-, jika huruf pertama adalah s*. Contoh: me- + sapu→ menyapu*.

# Sifat Khusus

- Dilebur jika huruf kedua kata dasar adalah huruf vokal. Contoh: me- + tipu → menipu, me- + sapu → menyapu, me- + kira → mengira.
- Tidak dilebur jika huruf kedua kata dasar adalah huruf konsonan. Contoh: me- + klarifikasi → mengklarifikasi.
- Tidak dilebur jika kata dasar merupakan kata asing yang belum diserap secara sempurna. Contoh: me- + konversi → mengkonversi.

# Masalah pada Stemming

- Understemming
  - jumlah kata/imbuhan yang dipotong terlalu sedikit
  - Misal: ”pengorbanan” menjadi ”korbanan”
- Overstemming
  - jumlah kata/imbuhan yang dipotong terlalu banyak
  - Misal: ”mencapai” menjadi ”capa”

# Pembobotan

- Perlunya suatu kata diberi bobot
  - Makin sering suatu kata muncul pada suatu dokumen, maka diduga semakin penting kata itu untuk dokumen tsb.
- Beberapa pendekatan:
  - tf
  - tf.idf
  - BM25
  - dsb.

# Term Frequency (tf)

- Frekuensi kemunculan suatu term **t** pada dokumen **d**→$\mathbf{tf_{t,d}}$
- Contoh:

| term | d1 | d2 | d3 | d4 | d5 |
|---|---|---|---|---|---|
| dari | 20 | 100 | 10 | 22 | 10 |
| database | 15 | 0 | 0 | 0 | 12 |
| dengan | 12 | 40 | 12 | 14 | 24 |
| informasi | 8 | 30 | 0 | 0 | 18 |
| komputer | 10 | 35 | 0 | 0 | 0 |
| struktur | 0 | 24 | 6 | 10 | 10 |
| yang | 35 | 120 | 15 | 32 | 20 |

# TF-IDF

- TF-IDF (Term Frequency - Inverse Document Frequency) adalah metode untuk mengukur pentingnya sebuah kata dalam suatu dokumen relatif terhadap kumpulan dokumen (corpus).

# Langkah-langkah TF -IDF

Misalkan kita memiliki tiga dokumen berikut:

- **D1**: "kucing suka ikan"
- **D2**: "ikan hidup di air"
- **D3**: "kucing hidup di rumah"

# Langkah-langkah TF -IDF

1. Hitung Term Frequency (TF)

$$TF(t,d) = \frac{\text{jumlah kemunculan term } t \text{ dalam dokumen } d}{\text{total kata dalam dokumen } d}$$

| Term | TF(D1) | TF(D2) | TF(D3) |
|---|---|---|---|
| kucing | 1/3 = 0.33 | 0 | 1/4 = 0.25 |
| suka | 1/3 = 0.33 | 0 | 0 |
| ikan | 1/3 = 0.33 | 1/4 = 0.25 | 0 |
| hidup | 0 | 1/4 = 0.25 | 1/4 = 0.25 |
| di | 0 | 1/4 = 0.25 | 1/4 = 0.25 |
| air | 0 | 1/4 = 0.25 | 0 |
| rumah | 0 | ↓ | 1/4 = 0.25 |

# Langkah-langkah TF -IDF

2. Hitung Inverse Document Frequency (IDF)

$$IDF(t) = \log \frac{N}{DF(t)}$$

di mana:

$N$ = jumlah total dokumen

$DF(t)$ = jumlah dokumen yang mengandung term $t$

# Langkah-langkah TF -IDF

| Term | DF (Jumlah Dokumen) | IDF (log(3/DF)) |
|---|---|---|
| kucing | 2 | log(3/2) = 0.18 |
| suka | 1 | log(3/1) = 0.48 |
| ikan | 2 | log(3/2) = 0.18 |
| hidup | 2 | log(3/2) = 0.18 |
| di | 2 | log(3/2) = 0.18 |
| air | 1 | log(3/1) = 0.48 |
| rumah | 1 | log(3/1) = 0.48 |

# Langkah-langkah TF -IDF

3. Hitung TF-IDF

$$TF - IDF(t, d) = TF(t, d) \times IDF(t)$$

Sebagai contoh, untuk kata "kucing" dalam D1:

$$TF - IDF(\text{kucing}, D1) = 0.33 \times 0.18 = 0.059$$

# Langkah-langkah TF -IDF

| Term | TF-IDF(D1) | TF-IDF(D2) | TF-IDF(D3) |
|---|---|---|---|
| kucing | 0.059 | 0 | 0.045 |
| suka | 0.159 | 0 | 0 |
| ikan | 0.059 | 0.045 | 0 |
| hidup | 0 | 0.045 | 0.045 |
| di | 0 | 0.045 | 0.045 |
| air | 0 | 0.120 | 0 |
| rumah | 0 | 0 | 0.120 |

TF-IDF menunjukkan bahwa kata "suka" dalam **D1** dan kata "air" dalam **D2** lebih penting karena memiliki nilai TF-IDF lebih tinggi.